

Классификация писем: спам/ не спам

СИНЕЛЬНИКОВА ЮЛИЯ, 331 ГРУППА

Описание датасета

- Набор данных **Spambase** был собран специалистами для решения задачи классификации электронных писем на спам и не-спам.
- Датасет содержит информацию о **4601** электронном письме и включает **57** признаков
- Большую часть признаков (48) составляют частоты определенных слов в письме, выраженные в процентах от общего числа слов
- Дополнительно используются 6 признаков частоты специальных символов (таких как ;, !, \$), а также 3 признака, характеризующих использование заглавных букв: средняя, максимальная и суммарная длина последовательностей заглавных букв.
- Интересной особенностью датасета является наличие персонализированных индикаторов не-спама: слова George (имя сотрудника) и код региона 650, которые часто встречаются в легитимной рабочей переписке.
- Целевая метка принимает значение **1** для спама и **0** для обычных писем.

Обзор признаков

Признаки делятся на четыре логические группы

- **Частота слов (48 признаков): word_freq_WORD**

- Представляют собой процентное соотношение: $100 * (\text{число вхождений слова в письмо}) / (\text{общее число слов в письме})$.
- Словарь включает такие слова
как: make, address, all, 3d, our, over, remove, internet, order, mail, receive, will, people, report, addresses, free, business, email, you, credit, your, font, 000, money, hp, hpl, george, 650, lab, labs, telnet, 857, data, 415, 85, technology, 1999, parts, pm, direct, cs, meeting, original, project, re, edu, table, conference.

- **Частота символов (6 признаков): char_freq_CHAR**

- Процентное соотношение: $100 * (\text{количество вхождений символа}) / (\text{общее число символов в письме})$.
- Символы: ;, (, [, !, \$, #.

- **Статистика заглавных букв (3 признака)**

- capital_run_length_average — средняя длина непрерывной последовательности заглавных букв
- capital_run_length_longest — длина самой длинной непрерывной последовательности заглавных букв
- capital_run_length_total — общая сумма длин всех непрерывных последовательностей заглавных букв (по сути, **общее количество заглавных букв в письме**) (целое, от 1).

- **Целевая переменная (1 признак): spam**


- Указывает, является письмо спамом (1) или нет (0).

Первый взгляд на данные

Spam

0 0.605955

1 0.394045




Выясним теперь такую вещь:

- Рассмотрим среднюю частоту каждого признака для писем - спама и писем - не спама
- Найдем отношение средней частоты каждого признака в письмах-спаме к средней частоте в признаках не спама
- Определим те признаки, которые гораздо чаще встречаются в спаме, нежели не в спаме
- Выдвигаем гипотезу, что эти признаки больше коррелируют со спамом

```
word_freq_3d      120.870445
word_freq_000     22.667510
word_freq_remove  19.086774
word_freq_credit  17.634169
char_freq_$       9.740393
dtype: float64
```


- Изобразим гистограммы для распределения признаков, характеризующихся наиболее высокими значениями в предыдущем разделе



Вычислим корреляцию

Топ-10 признаков,
коррелирующих со спамом:

word_freq_your 0.383234
word_freq_000 0.334787
word_freq_remove 0.332117
char_freq_\$ 0.323629
word_freq_you 0.273651
word_freq_free 0.263215
word_freq_business 0.263204
capital_run_length_total 0.249164
word_freq_our 0.241920
char_freq_! 0.241888




Начинаем машинное обучение

- Подготовим данные. Применим процедуры сдвига и масштабирования. Посмотрим на то, что мог бы нам дать метод главных компонент

```
n_components = 53
pca = PCA(n_components=n_components)
X_pca_train = pca.fit_transform(X_train)
print(f"Объясненная дисперсия: {pca.explained_variance_ratio_}")
|
```

```
Объясненная дисперсия: [0.11824283 0.05733768 0.03539854 0.02794696 0.02712179 0.02614975
0.02520496 0.02406443 0.02307607 0.0223152 0.02111836 0.02031382
0.01959424 0.01928632 0.01914644 0.01879037 0.01825965 0.01797933
0.01794621 0.01755438 0.01740566 0.01721041 0.01687834 0.01651117
0.01639254 0.01622178 0.01587141 0.01561839 0.01522173 0.01491882
0.01462309 0.01437852 0.01398144 0.01376816 0.01336645 0.01307793
0.01293022 0.01274685 0.01251385 0.01224509 0.01181987 0.01137943
0.01091306 0.01064566 0.01027484 0.00972716 0.00884816 0.00855268
0.00787401 0.0072234 0.00649532 0.00598605 0.00554309]
```

- По всей видимости, метод главных компонент, конечно, позволяет редуцировать количество признаков, но в данной задаче он недостаточно эффективен. Для того, чтобы убедиться в этом наверняка построим зависимость объясненной дисперсии от количества главных компонент



Для сохранения 95% дисперсии нужно 48 компонент

Как мы видим из 53 признаков у нас оказывается 48, объясняющих 95% дисперсии. Но это крайне маленькое редуцирование, поэтому даже не будем его применять.

Реализуем логистическую регрессию


Для улучшения обобщающей способности получающейся модели, то есть уменьшения эффекта переобучения, рассмотрим логистическую регрессию с регуляризацией L1

$$L_1 = \sum_i (y_i - y(t_i))^2 + \lambda \sum_i |a_i|.$$


Основные метрики по обучению модели

	precision	recall	f1-score	support
not spam	0.93	0.95	0.94	558
spam	0.92	0.89	0.91	363
accuracy			0.93	921
macro avg	0.92	0.92	0.92	921
weighted avg	0.93	0.93	0.93	921

Матрица ошибок



ROC-кривая



Провели валидацию и посмотрели влияние гиперпараметров на нашу модель логистической регрессии.

```
{'C': 10, 'penalty': 'l1', 'solver': 'liblinear'}  
precision recall f1-score support  
0 0.92982 0.94982 0.93972 558  
1 0.92023 0.88981 0.90476 363  
  
accuracy 0.92617 921  
macro avg 0.92503 0.91981 0.92224 921  
weighted avg 0.92604 0.92617 0.92594 921
```

оптимизировали ROC-AUC метрику

Усилим precision

	precision	recall	f1-score	support
0	0.92	0.96	0.94	558
1	0.93	0.88	0.90	363
accuracy			0.93	921
macro avg	0.93	0.92	0.92	921
weighted avg	0.93	0.93	0.93	921

Попробуем теперь решить задачу классификации с помощью **Многослойной нейронной сети**

- Создадим специальный класс для Перцептрона и пропишем для него функции `trainer` и `tester`
- 5 скрытых слоёв, размерность 64, dropout $p=0.1$, $lr=0.01$.

	ACCURACY
<code>{'hidden_dim': 8, 'lr': 0.01, 'num_layers': 5, 'p': 0.1}</code>	0.93
<code>{'hidden_dim': 8, 'lr': 0.01, 'num_layers': 5, 'p': 0.5}</code>	0.92
<code>{'hidden_dim': 8, 'lr': 0.01, 'num_layers': 10, 'p': 0.1}</code>	0.92
<code>{'hidden_dim': 8, 'lr': 0.01, 'num_layers': 10, 'p': 0.5}</code>	0.65
<code>{'hidden_dim': 64, 'lr': 0.01, 'num_layers': 5, 'p': 0.1}</code>	0.93
<code>{'hidden_dim': 64, 'lr': 0.01, 'num_layers': 5, 'p': 0.5}</code>	0.94
<code>{'hidden_dim': 64, 'lr': 0.01, 'num_layers': 10, 'p': 0.1}</code>	0.93
<code>{'hidden_dim': 64, 'lr': 0.01, 'num_layers': 10, 'p': 0.5}</code>	0.83

Accuracy of our model is: 0.9218241042345277

Classification report:

	precision	recall	f1-score	support
0	0.92	0.96	0.94	558
1	0.93	0.87	0.90	363
accuracy			0.92	921
macro avg	0.92	0.91	0.92	921
weighted avg	0.92	0.92	0.92	921

Сравнение метрик

1. Accuracy (точность)

- **Логистическая регрессия: ≈ 0.93 (93%)**
- **Нейронная сеть: ≈ 0.922 (92.2%)**

3. Recall (полнота)

- **Логистическая регрессия (базовая): 0.89**
- **Логистическая регрессия (усиление precision): 0.88**
- **Нейронная сеть: 0.87**

2. Precision (точность для каждого класса).

- **Логистическая регрессия (базовая): 0.92**
- **Логистическая регрессия (усиление precision): 0.93**
- **Нейронная сеть: 0.93**

4. F1-score

- **Логистическая регрессия (базовая): 0.91 (спам)**
- **Нейронная сеть: 0.90 (спам)**

Вывод

- 1) Наиболее информативные признаки для обнаружения спама – это частоты слов **your, 000, remove, you, free, business, our**, а также символы **\$** и **!** и общее количество заглавных букв. Эти признаки имеют корреляцию со спамом от 0.24 до 0.38.
- 2) Метод главных компонент (РСА) оказался неэффективным для этого набора данных, так как признаки слабо коррелируют между собой. Для сохранения 95% дисперсии потребовалось 48 компонент из 57 – редукция незначительна.
- 3) Логистическая регрессия с L1-регуляризацией показала лучший результат: accuracy 93%, ROC-AUC 0.967.
- 4) Настройка гиперпараметров позволила достичь компромисса между precision и recall. В частности, мы смогли повысить precision спама до 0.93, пожертвовав recall (0.88).
- 5) Многослойная нейронная сеть (перцептрон с 5 скрытыми слоями) дала accuracy 92.
- 6) Учитывая большую сложность и время обучения, для данной задачи предпочтительнее использовать логистическую регрессию – она проще в интерпретации и быстрее работает.